ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA CÔNG NGHỆ THÔNG TIN

----o0o----



ĐỒ ÁN MÔN HỌC

SINH CHÚ THÍCH TỪ ẢNH (IMAGE CAPTIONING)

Khảo sát và so sánh hai hướng tiếp cận: BLIP-2 và LLaVA

Sinh viên:

Hoàng Khang — MSSV: 24120334

TP. Hồ Chí Minh, 2026

Chương 1. Giới thiệu

1.1. Bối cảnh chung

Sinh chú thích từ ảnh (image captioning) là bài toán tự động tạo ra câu mô tả ngôn ngữ tự nhiên cho nội dung của một bức ảnh. Đây là bài toán nền tảng kết nối hai lĩnh vực thị giác máy tính và xử lý ngôn ngữ tự nhiên, được nghiên cứu liên tục trong hơn một thập kỷ qua.

Các mô hình đầu tiên theo kiến trúc mã hóa–giải mã (CNN–RNN) như Show and Tell [4] và bản mở rộng có cơ chế chú ý Show, Attend and Tell [5]. Giai đoạn tiếp theo, attention theo vùng đối tượng [6] trở thành chuẩn mực. Gần đây, với sự xuất hiện của kiến trúc Transformer và các mô hình tiền huấn luyện thị giác–ngôn ngữ như CLIP [8], bài toán chuyển sang hướng mô hình ngôn ngữ lớn đa mô thức (MLLM) [1]. Hai đại diện tiêu biểu cho hướng hiện đại là BLIP-2 [11] và LLaVA [12, 13] — cũng là trọng tâm khảo sát của đồ án này.

1.2. Động lực nghiên cứu

Ý nghĩa khoa học

Image captioning là bài toán thách thức vì đòi hỏi mô hình vừa "nhìn" đúng nội dung ảnh, vừa diễn đạt mạch lạc bằng ngôn ngữ. Việc khảo sát quá trình phát triển từ CNN–RNN đến MLLM giúp hiểu rõ các bước tiến về kiến trúc và dữ liệu. Ngoài ra, các vấn đề mở như hiện tượng "ảo giác" (hallucination) — mô hình mô tả những đối tượng không có trong ảnh [15, 16] — vẫn đang là hướng nghiên cứu thời sự, cho thấy bài toán chưa được giải quyết trọn vẹn.

Ý nghĩa thực tiễn

Sinh chú thích từ ảnh có nhiều ứng dụng thực tế: hỗ trợ người khiếm thị đọc nội dung ảnh (alt-text), lập chỉ mục và tìm kiếm ảnh theo ngôn ngữ, tự động mô tả sản phẩm trong thương mại điện tử, và đặc biệt là tự động tạo chú thích cho hình ảnh, biểu đồ trong tài liệu học thuật. Với ảnh chuyên ngành như đồ thị và biểu đồ khoa học, các công cụ hiện có còn hạn chế về chất lượng [27, 28], mở ra khoảng trống để cải thiện.

1.3. Phát biểu bài toán

Đầu vào và đầu ra

Đầu vào (Input): một bức ảnh tĩnh. Đầu ra (Output): một câu (hoặc đoạn) mô tả bằng ngôn ngữ tự nhiên nội dung của ảnh đó. Khác với hỏi–đáp theo ảnh (VQA) — nơi người dùng đưa kèm câu hỏi — bài toán captioning dùng một chỉ dẫn mô tả cố định (ví dụ "hãy mô tả ảnh này"), nên câu lệnh không thay đổi theo người dùng.

Framework chung của hệ thống

Một hệ thống sinh chú thích từ ảnh nhìn chung gồm các công đoạn chính sau (chưa đi vào phương pháp cụ thể):

- Tiền xử lý ảnh: chuẩn hóa kích thước, độ phân giải, định dạng đầu vào.

- Trích xuất đặc trưng thị giác: bộ mã hóa ảnh (vision encoder) biến ảnh thành biểu diễn số.
- Kết nối thị giác–ngôn ngữ: mô-đun cầu nối đưa đặc trưng ảnh vào không gian ngôn ngữ.
- Sinh chú thích: bộ giải mã ngôn ngữ (decoder / LLM) tạo câu mô tả.
- Đánh giá: so câu sinh ra với câu tham chiếu bằng các chỉ số (CIDEr, SPICE, CLIPScore…).

1.4. Đóng góp

Báo cáo được thực hiện dưới dạng khảo sát, với các đóng góp chính:

- Tổng hợp và hệ thống hóa quá trình phát triển của bài toán sinh chú thích từ ảnh, từ CNN–RNN đến các mô hình ngôn ngữ lớn đa mô thức.
- Chọn lọc và phân tích các công trình tiêu biểu theo hai hướng BLIP-2 **[11]** và LLaVA **[12, 13]**.
- Lập bảng so sánh các mô hình theo nhiều tiêu chí (hiệu năng, nguyên lý, tính năng, khả năng cài đặt) để trả lời câu hỏi: người ta đã làm gì, và đâu là giải pháp phù hợp nhất mà một đồ án sinh viên có thể cài đặt lại.

Chương 2. Các công trình nghiên cứu liên quan

2.1. Quá trình phát triển của các giải pháp

Giai đoạn nền tảng (2015–2018): bài toán được định hình bằng kiến trúc mã hóa–giải mã. Show and Tell **[4]** dùng CNN mã hóa ảnh và LSTM sinh câu. Show, Attend and Tell **[5]** bổ sung cơ chế chú ý thị giác. Bottom-Up and Top-Down **[6]** chuyển sang chú ý theo vùng đối tượng, trở thành chuẩn mực nhiều năm.

Giai đoạn tiền huấn luyện thị giác–ngôn ngữ (2021–2022): CLIP **[8]** học biểu diễn ảnh–văn bản từ dữ liệu web quy mô lớn. BLIP **[10]** hợp nhất hiểu và sinh, đồng thời làm sạch dữ liệu nhiễu bằng kỹ thuật CapFilt.

Giai đoạn mô hình ngôn ngữ lớn đa mô thức (2023 đến nay): BLIP-2 **[11]** nối bộ mã hóa ảnh đóng băng với mô hình ngôn ngữ lớn đóng băng qua Q-Former nhẹ. LLaVA **[12]** và bản cải tiến LLaVA-1.5 **[13]** đưa ra hướng visual instruction tuning. Các mô hình mới hơn như Qwen2-VL **[24]** tiếp tục nâng chất lượng và hỗ trợ đa ngôn ngữ. Song song, các nghiên cứu về hallucination **[15, 16]** và về đánh giá **[19, 21, 22]** hoàn thiện bức tranh.

2.2. Bảng so sánh các giải pháp

Dưới đây là bảng so sánh bốn mô hình đại diện theo các tiêu chí tự chọn, tập trung vào hiệu năng, nguyên lý, tính năng và khả năng cài đặt. (Bản gốc LLaVA **[12]** đã được LLaVA-1.5 **[13]** thay thế về hiệu năng nên dùng LLaVA-1.5 làm đại diện.)

Bảng 2.1. So sánh các mô hình sinh chú thích từ ảnh

Tiêu chí	BLIP (2022) [10]	BLIP-2 (2023) [11]	LLaVA-1.5 (2023) [13]	Qwen2-VL (2024) [24]
Venue / phản biện	ICML 2022 — đã phản biện	ICML 2023 — đã phản biện	CVPR 2024 — đã phản biện	Preprint (tech report) — chưa phản biện
Nguyên lý / kiến trúc	VLP hợp nhất hiểu + sinh; MED + CapFilt làm sạch dữ liệu web	ViT đóng băng + Q-Former + LLM đóng băng; huấn luyện 2 giai đoạn	CLIP ViT-336px + MLP projection + Vicuna-1.5; visual instruction tuning (cải tiến LLaVA)	Vision encoder + Qwen2 LLM; Naive Dynamic Resolution, M-RoPE
Cỡ mô hình (nhẹ nhất)	~0,4 tỷ tham số	2,7B / 6,7B (OPT, FlanT5)	7B / 13B (Vicuna-1.5)	2B / 7B / 72B
Tài nguyên (VRAM ước tính)	Rất nhẹ (có thể chạy CPU)	~8–16 GB (bản 2.7B)	~16 GB (bản 7B)	7B: ~16GB; 72B: hàng chục GB
Môi trường chạy được	CPU / Colab free	Colab free (bản nhỏ)	Colab (GPU) / GPU ≥16GB	7B: Colab Pro; 72B: server GPU lớn
Chất lượng caption	Trung bình (nền)	Cao, SOTA tại thời điểm ra	Rất cao; SOTA 11 benchmark	Rất cao; ngang GPT-4o (bản 72B)
Mức hallucination	Trung bình–cao	Trung bình (kế thừa từ LLM)	Trung bình (đo được bằng POPE [16])	Thấp hơn (mô hình mới, mạnh)
Độ chi tiết mô tả	Ngắn, cô đọng	Trung bình	Chi tiết, kiểm soát tốt hơn	Rất chi tiết; đọc được chữ/biểu đồ
Đa ngôn ngữ / tiếng Việt	Chủ yếu tiếng Anh	Chủ yếu tiếng Anh	Chủ yếu tiếng Anh	Đa ngôn ngữ (gồm tiếng Việt)
Tính năng chính	Captioning, retrieval, VQA	Captioning, VQA, zero-shot	Captioning, VQA, chat; đa benchmark	Caption, VQA, OCR, video, agent
Code & tài liệu	LAVIS/BLIP — rõ ràng	LAVIS — rõ ràng	Repo LLaVA — rất phổ biến, dễ tái lập	Repo Qwen2-VL — tốt
Khả năng cài đặt (đồ án SV)	Dễ nhất (nhẹ, nhưng yếu)	Dễ (nhẹ, chất lượng khá)	Trung bình (cân bằng tốt nhất)	7B: khó vừa; 72B: không khả thi

Ghi chú: VRAM là bộ nhớ card đồ họa cần để chạy; số liệu mang tính ước lượng tham khảo, phụ thuộc bản cài đặt và độ phân giải ảnh.

Đánh giá từng mô hình

- **BLIP [10]:** Nhẹ nhất, chạy được cả trên CPU, nhưng chất lượng caption thấp nhất và hay sai. Phù hợp làm mốc tham chiếu (baseline nền), không nên làm giải pháp chính.
- **BLIP-2 [11]:** Cân bằng tốt giữa chất lượng và tài nguyên; bản 2.7B chạy được trên Colab miễn phí. Là đại diện tiêu biểu cho hướng "frozen encoder + Q-Former". Lựa chọn tốt nếu máy/tài nguyên hạn chế.
- **LLaVA-1.5 [13]:** Chất lượng rất cao (SOTA trên 11 benchmark tại thời điểm công bố), code phổ biến và dễ tái lập, bản 7B chạy được trên Colab GPU. Cân bằng tốt nhất giữa chất lượng và khả năng cài đặt cho một đồ án sinh viên.
- **Qwen2-VL [24]:** Chất lượng cao nhất, hỗ trợ tiếng Việt và đọc được biểu đồ/văn bản trong ảnh; nhưng bản mạnh (72B) không khả thi với phần cứng sinh viên, và là bản preprint chưa qua phản biện. Bản 7B có thể cân nhắc nếu có Colab Pro.

Ghi chú: bản gốc LLaVA [12] mở ra hướng visual instruction tuning nhưng đã bị LLaVA-1.5 thay thế về hiệu năng, nên bảng trên dùng LLaVA-1.5 làm đại diện cho hướng này.

Kết luận — lựa chọn tối ưu có thể cài đặt

Mô hình nên chọn: LLaVA-1.5 (bản 7B).

Lý do: đây là điểm cân bằng tốt nhất giữa chất lượng caption (rất cao, đã qua phản biện CVPR 2024) và khả năng cài đặt thực tế (bản 7B chạy được trên Google Colab GPU miễn phí/Pro, code rõ ràng và được cộng đồng tái lập rộng rãi). Các mô hình mạnh hơn (Qwen2-VL-72B [24], InternVL lớn [23]) cho chất lượng cao hơn nhưng vượt quá phần cứng của một đồ án sinh viên.

Phương án so sánh trong Chương 4: để báo cáo có chiều sâu, nên chạy đối chứng LLaVA-1.5 với BLIP-2 (bản nhẹ) trên cùng một tập ảnh và cùng bộ chỉ số (CIDEr [19], CLIPScore [21]), thay vì chỉ chạy một mô hình.

Lưu ý môi trường: MacBook (kể cả chip M) không có GPU NVIDIA/CUDA nên dùng để đọc tài liệu và viết báo cáo; phần chạy thử nên thực hiện trên Google Colab.

2.3. Người ta đã làm gì, và mình muốn làm gì

Người ta đã làm được gì

Các mô hình hiện đại (BLIP-2, LLaVA-1.5, Qwen2-VL) đã sinh được chú thích chất lượng cao cho ảnh đời thường, đạt điểm tốt trên các benchmark chuẩn như COCO Captions [18] và nocaps [22]. Về công cụ ứng dụng, các phần mềm văn phòng cũng đã tích hợp tự động sinh mô tả ảnh. Tuy nhiên, chất lượng mô tả đối với ảnh chuyên ngành (biểu đồ, đồ thị khoa học) vẫn còn hạn chế và hay mắc lỗi dữ kiện [27, 28].

Mình muốn làm gì

Đồ án tập trung khảo sát và so sánh hai hướng BLIP-2 và LLaVA cho bài toán sinh chú thích từ ảnh, từ đó chọn một giải pháp tiên tiến mà vẫn cài đặt được với tài nguyên của sinh viên để trình bày nguyên lý (Chương 3) và chạy thử nghiệm đối chứng (Chương 4). Dựa trên bảng so sánh, LLaVA-1.5 (bản 7B) **[13]** là ứng viên cân bằng tốt nhất giữa chất lượng và khả năng cài đặt; BLIP-2 **[11]** được dùng làm mô hình đối chứng nhẹ hơn.

Tài liệu tham khảo

Mã số trong ngoặc vuông tương ứng với danh mục 28 tài liệu đã khảo sát. Dưới đây liệt kê các tài liệu được trích dẫn trong báo cáo này.

[1] Yin, S. et al. (2023/2024). A Survey on Multimodal Large Language Models. National Science Review. arXiv:2306.13549.

[4] Vinyals, O. et al. (2015). Show and Tell: A Neural Image Caption Generator. CVPR 2015. arXiv:1411.4555.

[5] Xu, K. et al. (2015). Show, Attend and Tell. ICML 2015. arXiv:1502.03044.

[6] Anderson, P. et al. (2018). Bottom-Up and Top-Down Attention. CVPR 2018. arXiv:1707.07998.

[8] Radford, A. et al. (2021). Learning Transferable Visual Models from Natural Language Supervision (CLIP). ICML 2021. arXiv:2103.00020.

[10] Li, J. et al. (2022). BLIP. ICML 2022. arXiv:2201.12086.

[11] Li, J. et al. (2023). BLIP-2. ICML 2023. arXiv:2301.12597.

[12] Liu, H. et al. (2023). Visual Instruction Tuning (LLaVA). NeurIPS 2023. arXiv:2304.08485.

[13] Liu, H. et al. (2023). Improved Baselines with Visual Instruction Tuning (LLaVA-1.5). CVPR 2024. arXiv:2310.03744.

[15] Rohrbach, A. et al. (2018). Object Hallucination in Image Captioning (CHAIR). EMNLP 2018. arXiv:1809.02156.

[16] Li, Y. et al. (2023). Evaluating Object Hallucination in LVLMs (POPE). EMNLP 2023. arXiv:2305.10355.

[18] Chen, X. et al. (2015). Microsoft COCO Captions. arXiv:1504.00325.

[19] Vedantam, R. et al. (2015). CIDEr. CVPR 2015. arXiv:1411.5726.

[21] Hessel, J. et al. (2021). CLIPScore. EMNLP 2021. arXiv:2104.08718.

[22] Agrawal, H. et al. (2019). nocaps. ICCV 2019. arXiv:1812.08658.

[23] Chen, Z. et al. (2023/2024). InternVL. CVPR 2024 (Oral). arXiv:2312.14238.

[24] Wang, P. et al. (2024). Qwen2-VL. arXiv:2409.12191 (preprint).

[27] Hsu, T.-Y. et al. (2021). SciCap: Generating Captions for Scientific Figures. Findings of EMNLP 2021. arXiv:2110.11624.

[28] Kantharaj, S. et al. (2022). Chart-to-Text. ACL 2022. arXiv:2203.06486.